



DISPARIDADE SALARIAL DOS PROFISSIONAIS DE DADOS NO BRASIL


Desvendando os Fatores que Influenciam a Remuneração e
Promovendo a Equidade

Integrantes: Pedro Dias Soares, Gabriel Chaves Nascimento, Enzo Alves Barcelos Gripp



PROBLEMA


- O Brasil vive uma transformação digital acelerada, impulsionando a demanda por profissionais de dados.
- No entanto, essa expansão é marcada por grandes disparidades salariais, influenciadas por múltiplos fatores.
- Empresas enfrentam dificuldades em definir salários justos, e profissionais não têm clareza sobre o que impulsiona sua remuneração.
- Estudos do IBGE e o próprio relatório State of Data Brasil 2023 apontam a influência de gênero, etnia, escolaridade e experiência nessas desigualdades.





NOSSO SISTEMA INTELIGENTE: RUMO À EQUIDADE SALARIAL

- Desenvolvemos um sistema inteligente que compreende e auxilia na equiparação salarial de profissionais de dados no Brasil.
- Utilizamos técnicas avançadas de Ciência de Dados para identificar padrões e tendências salariais.
- Nossa solução fornece insights claros sobre os fatores determinantes para a variação salarial.
- O objetivo é criar um padrão de remuneração mais equilibrado e transparente para o mercado de dados brasileiro.





IMPACTANDO O ECOSSISTEMA DE DADOS NO BRASIL

- Profissionais de Dados: Para avaliarem sua posição no mercado, planejarem o crescimento de carreira e negociarem com base em dados concretos.
- Gestores e Recrutadores de RH: Para definirem pacotes salariais competitivos, estruturarem políticas de retenção de talentos e promoverem a equidade.
- Pesquisadores e Acadêmicos: Para aprofundarem estudos sobre desigualdades salariais e tendências do mercado de trabalho em tecnologia.
- Órgãos Governamentais e Associações da Indústria: Para formularem políticas públicas eficazes e regulamentações que incentivem a igualdade salarial.



DA COLETA DE DADOS AO MODELO PREDITIVO

1. Coleta e Preparação de Dados: Utilizamos o State of Data Brasil 2023 e bases auxiliares (Censo da Educação Superior, Relatórios de Transparência Salarial, PNAD-C) para criar um dataset robusto.
2. Análise Exploratória (EDA): Identificamos padrões e relações visuais entre salários e fatores como experiência, escolaridade, gênero e região.
3. Engenharia de Features: Mapeamos e transformamos variáveis para otimizar o aprendizado dos modelos.
4. Modelagem Preditiva: Desenvolvemos e comparamos modelos de Machine Learning (Random Forest, Gradient Boosting, Redes Neurais) para prever e explicar as faixas salariais.
5. Interpretação e Validação: Analisamos o desempenho dos modelos e extraímos insights acionáveis.



DIFERENCIAIS DA NOSSA ANÁLISE E SOLUÇÃO


- Foco na Interação de Fatores: Investigamos como múltiplos fatores se interligam para impactar o salário (ex: como experiência e formação se combinam).
- Uso de Modelos Explicáveis (XAI): Além da previsão, focamos na interpretabilidade dos modelos para entender por que certas disparidades ocorrem.
- Tratamento de Classes Desbalanceadas: Técnicas avançadas garantem que o modelo aprenda bem, mesmo com faixas salariais menos comuns.
- Combinação de Fontes de Dados: Enriquecimento com dados do MEC e PNAD-C proporciona uma visão mais completa e contextualizada.
- Aplicação Interativa: O modelo final será disponibilizado em uma aplicação web, tornando-o acessível e prático para o público.





PRINCIPAIS INSIGHTS E DESEMPENHO DOS MODELOS

- Fatores Chave de Remuneração: A senioridade do cargo, o tempo de experiência e o nível de formação acadêmica são os maiores preditores salariais.
- Interação de Formação e Experiência: A formação acadêmica potencializa o retorno da experiência. Para os salários mais altos, é necessária a combinação de alta formação (Mestrado/Doutorado) E alta experiência.
- Impacto Regional e Demográfico: Região e gênero apresentam influência, mas com menor peso direto que senioridade/experiência. A RNA conseguiu capturar nuances do gênero e da região.
- Desempenho Preditivo: Nossos modelos (Random Forest, LightGBM, RNA) alcançaram acurácias e ROC AUCs robustos (ex: RNA com 83.8% de acurácia e 0.926 de ROC AUC), validando a capacidade de prever as faixas salariais.





EVOLUÇÃO CONTÍNUA DA NOSSA SOLUÇÃO

- Aprimoramento do Modelo: Explorar modelos de regressão para estimativa salarial exata e classificação ordinal para faixas.
- Enriquecimento de Dados: Incluir features de porte de empresa, tipo de contrato (CLT vs PJ), habilidades técnicas específicas e custo de vida por região.
- Análise de Causalidade e Equidade: Discutir a relação de causa e efeito e investigar vieses para promover a justiça salarial.
- Expansão da Aplicação: Desenvolver novas funcionalidades e dashboards para a plataforma web interativa.
- Interpretabilidade Aprofundada (XAI): Aplicar técnicas como SHAP e LIME para entender o "porquê" das previsões em nível individual.



TIME (QUEM FAZ ACONTECER)

- Pedro Dias Soares: [pdsoares@sga.pucminas.br]
- Gabriel Chaves Nascimento: [gabriel.nascimento.1483087@sga.pucminas.br]
- Enzo Alves Barcelos Gripp: [eabgripp@sga.pucminas.br]
- Professores Orientadores: Hugo Bastos de Paula, Hayala Nepomuceno Curto
- Curso e Instituição: Ciência de Dados, PUC Minas - Unidade Praça da Liberdade



CONECTE-SE CONOSCO!

[Nosso Repositório!](#)
(CLIQUE AQUI)