

Análise da Disparidade Salarial de Profissionais de Dados no Brasil

Integrantes:

Enzo Alves Barcelos Gripp
Gabriel Chaves Nascimento
Pedro Dias Soares

Professores:

Hayala Nepomuceno Curto
Hugo Bastos de Paula

Instituição:

Pontifícia Universidade Católica de Minas Gerais (PUC MINAS)
Curso de Ciência de Dados e Inteligência Artificial

Introdução e Contextualização

- O Brasil viveu uma expansão exponencial na indústria de dados, devido à transformação digital do país, isso resultou numa necessidade do mercado de trabalhadores qualificados.
- Contudo, essa necessidade repentina é um grande catalisador para a desigualdade socioeconômica, e por tanto, os profissionais de dados no Brasil estão sujeitos a este problema.

Problema, Objetivos e Justificativa



Problemas e objetivos: Empresas e funcionários tem dificuldades para determinar os seus respectivos salários de forma justa, pois não consideram os requisitos e variáveis necessárias para isso. Com base nisso, esse trabalho teve como objetivo criar um sistema inteligente capaz de identificar os fatores determinantes da variação salarial no mercado de dados no Brasil.



Justificativa: A pesquisa beneficia profissionais, que podem planejar melhor suas carreiras, e empresas, que poderão aplicar políticas salariais baseadas em dados concretos.


1ª Pergunta Orientada a dados

- **Pergunta:** *"Como fatores como formação acadêmica e experiência profissional interagem para influenciar a disparidade salarial entre profissionais de dados no Brasil?"*
- **Link da base de dados principal(State of Data 2023):**<https://www.kaggle.com/datasets/datahackers/state-of-data-brazil-2023>.
- **Link da base de dados auxiliar(Microdados do Censo da Educação Superior):**<https://www.gov.br/inep/pt-br/aceso-a-informacao/dados-abertos/microdados/censo-da-educacao-superior>

Atributo	Nome	Tipo	Relevância
P0	id	Qualitativo	Alta
P1l	Nível de ensino alcançado	Qualitativo	Alta
P1m	Área de formação acadêmica	Qualitativo	Alta
P2h	Faixa salarial mensal	Quantitativo	Alta
P2i	Tempo de experiência na área de dados	Qualitativo	Alta
P2g	Nível de senioridade	Qualitativo	Alta
P1b	Gênero do profissional	Qualitativo	Alta
P1c	Cor/Raça/Etnia	Qualitativo	Alta
P2b	Setor de atuação da empresa	Qualitativo	Alta
P1i1	UF onde mora	Qualitativo	Alta
P2f	Cargo atual	Qualitativo	Alta
P2o6	Oportunidade de aprendizado	Qualitativo	Alta
P2o10	Reputação da empresa	Qualitativo	Alta


Analise Exploratória de dados

- Demonstra uma clara correlação positiva entre o tempo de experiência na área de dados e o nível salarial.
- Profissionais com mais anos de atuação tendem a ter salários medianos mais altos e também uma maior variabilidade salarial.
- A progressão salarial parece ser mais acentuada nos primeiros anos de carreira, estabilizando-se em um patamar mais elevado para profissionais com 4 ou mais anos de experiência.



Analise Exploratória de dados

- **Quanto maior o nível de ensino, maior o salário.** Profissionais com mestrado e doutorado têm os maiores salários, mas também a maior variação de ganhos, com alguns alcançando valores excepcionalmente altos. Investir em educação formal, desde a graduação, aumenta significativamente o potencial de remuneração.




Resultado do Modelo 1.1

Tabela com métricas de desempenho:

Classe	Precisão	Recall	F1-Score	Suporte
Salário Baixo/Médio	0.84	0.84	0.84	568
Salário Alto	0.79	0.78	0.78	422
accuracy	0.81		0.82	990
macro avg	0.81	0.81	0.81	990
macro avg	0.81	0.82	0.82	990

Matriz de confusão


Matriz de Confusão: Mostra os acertos e erros do modelo em detalhes, com os números de falso positivos e negativos, mais os números de verdadeiros positivos e negativos.



interpretação do modelo 1.1

O gráfico demonstras o top 20 feactures mais relevantes do modelo:

- As barras de formação acadêmica, experiência profissional e senioridade, todas de características progressivas, são consideradas essenciais para o processo de decisão do modelo.




Funcionamento do Random Forest

O modelo do Random Forest funciona em 2 passos simples:

- **Uma Árvore de Decisão:** que se baseia em perguntas de sim/não.
- **A Floresta (Random Forest):** um conjunto de arvores com conjuntos de dados levemente diferentes.

Visualização Simplificada de uma Árvore do Random Forest



Indução do modelo

1.2

Para o modelo 1.2 (segundo modelo da 1ª pergunta orientada a dados), foi escolhido o modelo decision tree.


Porque decision tree?

- Excelente para lidar com múltiplas variáveis categóricas.
- Um bom modelo para classificação.

Atributo	Nome	Tipo	Relevância
P0	id	Qualitativo	Alta
P1l	Nível de ensino alcançado	Qualitativo	Alta
P1m	Área de formação acadêmica	Qualitativo	Alta
P2h	Faixa salarial mensal	Quantitativo	Alta
P2i	Tempo de experiência na área de dados	Qualitativo	Alta
P2g	Nível de senioridade	Qualitativo	Alta
P1b	Gênero do profissional	Qualitativo	Alta
P1c	Cor/Raça/Etnia	Qualitativo	Alta
P2b	Sector de atuação da empresa	Qualitativo	Alta
P1i1	UF onde mora	Qualitativo	Alta
P2f	Cargo atual	Qualitativo	Alta
P2o6	Oportunidade de aprendizado	Qualitativo	Alta
P2o10	Reputação da empresa	Qualitativo	Alta

Matriz de confusão

Matriz de Confusão: Mostra os acertos e erros do modelo em detalhes, com os números de Falso positivos e negativos, mais os números de Verdadeiros positivos e negativos.



Interpretação do modelo 1.2

A tabela mostra a importance features do modelo 1.2:


- Vemos claramente uma força influência do nível de ensino alcançado e da experiência.
- As demais feactures são consideradas pelo modelo irrelevantes.

Variável	Importância (%)	Interpretação Consolidada
nivel_cod	73.29%	Fortíssima influência
experiencia_num	23.72%	Forte influência
docentes_mestrado_regiao	0.82%	Baixa influência.
tecnicos_regiao	0.78%	Baixa influência.
docentes_regiao	0.70%	Baixa influência.
num_ies_regiao	0.70%	Baixa influência.

Funcionamento do Decision Tree

- Pense em um **fluxograma inteligente** que o computador aprende sozinho.

 O modelo faz uma série de perguntas "sim/não" para separar os dados e chegar a uma conclusão final.
- Ele sempre começa com a pergunta que melhor divide os grupos.



Análise comparativa dos modelos 1.1 e 1.2

Modelo 1.1

- Simplificação da análise dos salários (Baixo Vs Alto).
- Parcialmente interpretável, pois possui a importância das features e visualização individual das árvores, contudo ao juntar as 100 árvores se torna uma tarefa complexa.
- Trata formação e experiência como features **ordinais**, preservando a informação de ordem (Ex: Mestrado > Graduação), mas pode assumir que o impacto entre os níveis é equidistante.
- Bom desempenho, com acurácia balanceada entre as classes
- Utilizou o parâmetro `class_weight=balanced_subsample`, que ajusta o peso da classe minoritária dentro do próprio algoritmo para cada árvore do ensemble.

Modelo 1.2

- Maior complexidade da análise dos salários (6 classes).
- Menor interpretabilidade, pois o modelo é sequencial (boosting) e o raciocínio para prever 6 classes é intrinsecamente mais complexo.
- Usa **One-Hot Encoding**, tratando cada nível como uma categoria independente. Isso oferece mais flexibilidade, mas perde a informação de ordem inerente às variáveis.
- Desempenho indesejável, com acurácia desbalanceada entre as classes.
- Utilizou uma técnica de **oversampling manual** antes do treinamento, replicando as amostras das classes minoritárias para que todas tivessem o mesmo número de exemplos.

2ª Pergunta Orientada a dados


- **Pergunta:** *"Qual é a relação entre o tempo de experiência na área de dados, o nível de senioridade e a faixa salarial dos profissionais no Brasil?"*
- **Link da base de dados principal (State of Data 2023):** <https://www.kaggle.com/datasets/datahackers/state-of-data-brazil-2023>.
- **Link da base de dados auxiliar (Relatórios de Transparência Salarial e Critérios Remuneratórios):** <https://relatoriode transparencia salarial.trabalho.gov.br/>

Atributo	Nome	Tipo	Relevância
P2h	Faixa salarial mensal	Quantitativo	Alta
P2i	Tempo de experiência na área de dados	Qualitativo	Alta
P2g	Nível de senioridade	Qualitativo	Alta

Analise Exploratória de Dados


- Empresas que desejam atrair ou reter talentos mais seniores devem **oferecer modelos mais flexíveis**, enquanto aquelas que contratam muitos juniores devem planejar **infraestrutura presencial adequada**.

Modelo de Trabalho por Nível de Senioridade



Analise Exploratória de Dados

- A distribuição geográfica da renda está fortemente concentrada em poucos estados, o que pode impactar políticas públicas, alocação de recursos e estratégias de desenvolvimento regional.



Indução do modelo 2.1

Para o primeiro modelo 2.1 (primeiro modelo da 2ª pergunta orientada a dados), foi utilizado **Random Forest Regressor**.

Porque o Random Forest Regressor?

- Identificar o peso de fatores individuais Vs fatores regionais.

Processo de Amostragem e Treinamento de dados:

- **Divisão:** a divisão é na proporção de 75/25.

```
X_train, X_test, y_train, y_test = train_test_split(X, y, random_state=42)
```

- **Validação:** Avaliação realizada na amostra de teste (X_test, y_test) com métricas como MAE e R^2 .


```
# === Passo 7: Avaliar modelo ===  
print(f"MAE: {mean_absolute_error(y_test, y_pred):.2f}")  
print(f"R²: {r2_score(y_test, y_pred):.2f}")
```

Resultados do modelo 2.1

Métrica	Valor
MAE (Erro Médio Absoluto)	R\$ 2.882,21
R^2 (Coeficiente de Determinação)	0.38

Funcionamento do Random Forest Regressor

Funciona como um fluxograma para estimar um valor. Ela aprende a fazer uma série de perguntas sobre as características de um profissional, como "a experiência é maior que 5.5 anos?" ou "o nível é Sênior?", para dividi-los em grupos cada vez mais específicos e homogêneos. Ao final de cada "caminho" de perguntas, a árvore chega a um grupo final de indivíduos com perfis muito semelhantes. A previsão para essa única árvore é então calculada como a **média salarial** de todos os profissionais que pertencem a esse grupo final. E por fim igual ao random forest ele cria uma floresta ao integrar várias destas arvores.



Indução do modelo 2.2

Para o primeiro modelo 2.2 (segundo modelo da 2ª pergunta orientada a dados), foi utilizado **Random Forest Classifier**.

Porque o **Random Forest Classifier**?

- Constrói várias **árvores de decisão** e combina seus resultados para fazer previsões mais precisas.

Processo de Amostragem e Treinamento de dados:

- **Divisão:** a divisão é na proporção de 75/25.

```
X_train, X_test, y_train, y_test = train_test_split(X, y, random_state=42)
```

- **Validação:** Avaliação realizada na amostra de teste (X_test_c, y_test_c) com métricas como Acurácia, Matriz de Confusão e Relatório de Classificação (Precision, Recall, F1-score).

```
# Avaliação
print(f"Acurácia: {accuracy_score(y_test_c, y_pred_c):.2%}")
print("\nMatriz de Confusão:")
print(confusion_matrix(y_test_c, y_pred_c))
print("\nRelatório de Classificação:")
print(classification_report(y_test_c, y_pred_c, target_names=le_salario.classes_))
```

Resultados do modelo 2.1

Matriz de confusão:

	Predito: R\$ 1k-2k	Predito: R\$ 2k-3k	Predito: R\$ 3k-4k
Real: R\$ 1k-2k	0	1	0
Real: R\$ 2k-3k	0	1	0
Real: R\$ 3k-4k	0	1	0

0

Analise comparativa dos modelos 2.1 e 2.2

Modelo 2.1

- Possui saída com valor numérico (R\$/mês).
- Altamente interpretável, pois são valores fixos.
- Trata formação e experiência como features **ordinais**, preservando a informação de ordem (Ex: Mestrado > Graduação), mas pode assumir que o impacto entre os níveis é equidistante.
- Desempenho fraco.
- **Feature importances**: nível de ensino e experiencia dominantes.

Modelo 2.2

- Possui saída em faixas salariais.
- Menor interpretabilidade, pois os valores são separados em faixas que só vão na faixa de mil a 4 mil reais.
- Usa **One-Hot Encoding**, tratando cada nível como uma categoria independente. Isso oferece mais flexibilidade, mas perde a informação de ordem inerente às variáveis.
- Desempenho fraco.
- **Feature importances**: Não informativa (0% para todas as features devido à falha de aprendizado).


3ª Pergunta Orientada a dados

- **Pergunta:** *"Como fatores como formalidade no emprego, características demográficas se interagem com a proficiência técnica para influenciar as disparidades salariais entre profissionais de dados no Brasil?"*
- **Link da base de dados principal(State of Data 2023):**<https://www.kaggle.com/datasets/datahackers/state-of-data-brazil-2023>.
- **Link da base de dados auxiliar(PNAD-Continua):**<https://basedosdados.org/dataset/9fa532fb-5681-4903-b99d-01dc45fd527a?table=a04fc85d-908a-4393-b51d-1bd517a40210>

Atributo	Código de Referência	Tipo	Relevância
Faixa etária	P1a1	Qualitativo	Alta
Gênero	P1b	Qualitativo	Alta
Nível de ensino alcançado	P1l	Qualitativo	Alta
Faixa salarial mensal	P2h	Qualitativo	Alta
Tempo de experiência na área de dados	P2i	Qualitativo	Alta
UF onde mora	P1i1	Qualitativo	Alta
Cargo atual	P2f	Qualitativo	Alta
Nível de senioridade	P2g	Qualitativo	Alta


Análise Exploratória de dados

- O histograma sobreposto evidencia uma clara segmentação do mercado de dados em dois universos salariais distintos. Ele serve como um poderoso ponto de partida visual para investigar quais são os fatores determinantes que colocam um profissional em um ou outro grupo, respondendo diretamente à pergunta orientadora da análise.



Analise Exploratória de dados

- Na área de dados, experiência é crucial, mas a educação superior acelera e aumenta o potencial de ganhos.
- Salário não depende apenas de educação e experiência. A grande variação nos ganhos mostra que outros fatores, como suas habilidades técnicas, o tipo de contrato, a região onde você trabalha e seu perfil demográfico, também são decisivos.



Indução do modelo 3.1

Para modelo 3.1 (primeiro modelo da 3ª pergunta orientada a dados), foi utilizado o LightGBM.

Porque o lightGBM?

- Foco na precisão.
- Rápido e eficiente

Processo de Amostragem e Treinamento de dados:

- **Divisão Estratificada:** Divisão na proporção 75/25 para teste, mantendo a proporção de salários, "salários Baixos" Vs "salários Altos".

```
X_train_optuna, X_test, y_train_optuna, y_test = train_test_split(
    X_initial, y_full, test_size=0.25, random_state=42, stratify=y_full
)
print(f"Dados divididos em treino ({X_train_optuna.shape[0]}) e teste ({X_test.shape[0]}")
```


- **Validação cruzada estratificada para RFECV:** Treina o estimador (lgb.LGBMClassifier) recursivamente, removendo features e avaliando o desempenho (definido por rfecv_scoring, padrão 'accuracy') através da validação cruzada estratificada. Isso ajuda a encontrar o número de features que maximiza a métrica de scoring.

```
estimator_rfecv = lgb.LGBMClassifier(random_state=42, n_jobs=-1, verbose=-1)
cv_rfecv = StratifiedKFold(n_splits=rfecv_folds, shuffle=True, random_state=42)
rfecv_selector = RFECV(estimator=estimator_rfecv, step=rfecv_step, cv=cv_rfecv,
                      scoring=rfecv_scoring, min_features_to_select=1, n_jobs=-1, verbose=1)

rfecv_selector.fit(X_train_optuna_for_rfecv, y_train_optuna)
```

Matriz de confusão


Matriz de Confusão: Mostra os acertos e erros do modelo em detalhes, com os números de Falso positivos e negativos, mais os números de Verdadeiros positivos e negativos.



Interpretação do modelo 3.1


O gráfico demonstra as principais features importantes do modelo 3.1:

- Observa-se que a experiência (P2_i), o cargo atual (P2_f_Cargo_Atual) e o nível de senioridade (P2_g_Nivel) são os preditores mais fortes da faixa salarial.
- O nível de ensino (P1_l), a faixa etária (P1_a_1) e a região (Regiao_Mapeada) também apresentam contribuições significativas, sugerindo a influência de fatores demográficos e geográficos na remuneração



Funcionamento do LightGBM

- Diferente do Random Forest, que cria várias árvores independentes, o LightGBM funciona de forma sequencial. Cada nova árvore é treinada especificamente para **corrigir os erros** do modelo anterior. Em vez de ter várias opiniões aleatórias, ele vai construindo um especialista sobre o outro, fazendo pequenas melhorias focadas.



Indução do Modelo 3.2

Para o modelo 3.2 (segundo modelo da 3ª pergunta orientada a dados), foi escolhido o modelo Rede Neural com Embeddings e Otimização via Ray Tune (RNA v2) .

Porque Rede Neural com Embeddings?

- Maior capacidade de aprender interações complexas.
- Desempenho semelhante ao LightGBM.

Atributo	Código de Referência	Tipo	Relevância
Faixa etária	P1a1	Qualitativo	Alta
Gênero	P1b	Qualitativo	Alta
Nível de ensino alcançado	P1l	Qualitativo	Alta
Faixa salarial mensal	P2h	Qualitativo	Alta
Tempo de experiência na área de dados	P2i	Qualitativo	Alta
UF onde mora	P1i1	Qualitativo	Alta
Cargo atual	P2f	Qualitativo	Alta
Nível de senioridade	P2g	Qualitativo	Alta

Indução do modelo 1.2

Processo de Amostragem e treinamento de dados

- **Partionamento inicial:** A divisão seguiu a proporção 75/25.

```
# --- Preparação dos dados para Rede Neural ---
```

```
X_train_nn_full, X_test_nn_full, y_train_nn_full, y_test_nn_full = train_test_split(  
    X_initial_nn, y_full_nn, test_size=0.25, random_state=42, stratify=y_full_nn)
```


- **Particionamento interno para otimização de hiperparâmetros com Ray Tune:** Este conjunto de validação interno é usado por cada *trial* do Ray Tune para avaliar o desempenho do modelo Keras com uma dada combinação de hiperparâmetros. O callback EarlyStopping do Keras monitora a `val_accuracy` neste conjunto, e o `ReportCheckpointCallback` reporta essa métrica ao Ray Tune.

```
# Split para HPO
```

```
train_hpo_idx, val_hpo_idx = train_test_split(np.arange(len(y_train_nn_final_arr)), test_size=0.2, random_state=42, s  
X_train_hpo_list = [data[train_hpo_idx] for data in X_train_nn_inputs_final_list]  
y_train_hpo_arr = y_train_nn_final_arr[train_hpo_idx]  
X_val_hpo_list = [data[val_hpo_idx] for data in X_train_nn_inputs_final_list]  
y_val_hpo_arr = y_train_nn_final_arr[val_hpo_idx]
```

Matriz de confusão


Matriz de Confusão: Mostra os acertos e erros do modelo em detalhes, com os números de Falso positivos e negativos, mais os números de Verdadeiros positivos e negativos.



Interpretação do modelo 3.2


O gráfico demonstra a feacture importance do modelo 3.2:

- Fica nítido que o nível de ensino é a variável mais importante para a decisão do modelo.
- O cargo atual e o tempo de experiencia na área de dados, também possuem uma relevância na decisão do modelo.
- As demais tem importância secundaria.
- Exceto o Gênero que apresentou um impacto nulo na performance do modelo.



Funcionamento da Rede Neural

- Diferente de modelos que tratam todos os dados da mesma forma, esta rede neural é especialista em entender a **natureza diferente** das suas informações (textos e números).
- Ela primeiro **traduz as categorias** (como Cargo, Nível de Ensino) em "**coordenadas inteligentes**" usando camadas de **Embedding**. Isso permite que a rede aprenda a relação de similaridade entre os textos.
- Em seguida, ela **combina** essas "coordenadas" com os dados numéricos (como Tempo de Experiência) e usa essa visão unificada para encontrar padrões complexos e fazer a previsão final.



Analise comparativa dos modelos 3.1 e 3.2

Modelo 3.1

- Possui saída com valor numérico (R\$/mês).
- Interpretável, mas com limitações.
- Captura certas relações mas com menos complexidade.
- Desempenho bom.
- Leve e rápido.

Modelo 3.2

- Possui saída em faixas salariais.
- Menor interpretabilidade, pois exige ferramentas mais complexas para compreender.
- Captura interações complexas automaticamente.
- Desempenho bom.
- Mais pesado e demorado.

Conclusão

- **Principais Fatores que Influenciam o Salário:**
 - **Pilares Fundamentais:** Senioridade, Cargo e Experiência emergiram consistentemente como os preditores mais dominantes da faixa salarial em todos os modelos.
 - **Fator Amplificador:** A formação acadêmica sólida demonstrou amplificar o retorno salarial obtido com a experiência, abrindo caminho para remunerações mais altas.
 - **Influências Secundárias:** Gênero e Região (Sudeste/Sul) foram identificados como fatores de impacto secundário, mas relevante, especialmente pelo modelo de Rede Neural, que capturou interações mais complexas.

Obrigado!